

گزارش پروژه
طبقه‌بندی تصاویر خودرو

مقایسه مدل CNN پایه، تکنیک‌های بهبود و Transfer Learning با ResNet

چکیده

هدف این پروژه طراحی و ارزیابی یک سامانه طبقه‌بندی تصاویر خودرو در هشت کلاس مختلف بود. برای بررسی مرحله‌به‌مرحله عوامل مؤثر بر عملکرد، ابتدا یک شبکه CNN پایه طراحی و به‌عنوان سنگ محک استفاده شد. سپس مجموعه‌ای از آزمایش‌های کنترل‌شده شامل Augmentation, Dropout, Average Pooling, Learning Rate Scheduler, Weight Decay و بررسی اثر عدم توازن داده انجام شد. در ادامه، برای بررسی اثر افزایش ظرفیت مدل و استفاده از دانش از پیش‌آموزش‌شده، یک ResNet۱۸ آموزش‌دیده روی ImageNet در دو حالت Freeze و Fine-tune ارزیابی شد. همچنین اثر استفاده از Binary Cross-Entropy در مقایسه با Cross-Entropy بررسی شد. نتایج نشان داد تغییرات کوچک در CNN پایه تنها بهبودهای محدودی ایجاد کردند و در برخی موارد حتی باعث افت عملکرد شدند. در مقابل، استفاده از ResNet۱۸ باعث جهش محسوسی در عملکرد شد. مدل ResNet با Backbone فریزشده به Accuracy برابر ۹۰ درصد و Macro F۱ برابر ۰.۸۹ رسید و مدل Fine-tuned بهترین نتیجه را با Accuracy برابر ۹۶ درصد و Macro F۱ برابر ۰.۹۶ روی مجموعه آزمون ۴۰۰ تصویری به دست آورد. بنابراین، مهم‌ترین عامل بهبود در این پروژه افزایش ظرفیت و استفاده مؤثر از ویژگی‌های از پیش‌آموزش‌شده بوده است.

1. مقدمه

طبقه‌بندی تصاویر خودرو یکی از مسائل رایج در پردازش تصویر و بینایی ماشین است که در آن مدل باید با توجه به ویژگی‌های بصری، تصویر ورودی را به یکی از کلاس‌های از پیش تعیین‌شده اختصاص دهد. در این پروژه مسئله شامل هشت کلاس ambulance, autobus, kamyun, vanet و kamyunet, minibus, savari, taxi بود و هر تصویر تنها به یک کلاس تعلق داشت.

برای شروع، یک CNN اختصاصی با چهار بلوک کانولوشنی طراحی شد. در هر بلوک عملیات کانولوشن، Batch Normalization, ReLU و Pooling انجام شد و در بخش طبقه‌بندی از Adaptive Average Pooling, Flatten و دو لایه Fully Connected استفاده شد. این مدل بدون Augmentation و تکنیک‌های اضافی آموزش داده شد تا معیار مناسبی برای مقایسه آزمایش‌های بعدی فراهم کند.

پس از ارزیابی مدل پایه، آزمایش‌ها به‌صورت Ablation و مقایسه‌ای ادامه یافتند. هدف این بود که مشخص شود آیا مسئله اصلی با تنظیم روش آموزش و Regularization حل می‌شود یا اینکه محدودیت اصلی از ظرفیت معماری ناشی می‌شود. در مرحله بعد، استفاده از ResNet۱۸ و Transfer Learning این فرض را آزمایش کرد.

2. روش انجام پروژه

2-1. مدل CNN پایه

مدل پایه از چهار لایه کانولوشنی تشکیل شده است و بین بلوک‌ها Batch Normalization, ReLU و Max Pooling قرار دارد. پس از آخرین بلوک، Adaptive Average Pooling با خروجی 1×1 اعمال شده و سپس ویژگی‌ها وارد لایه Fully Connected می‌شوند. لایه خطی اول ۲۵۶ ویژگی ورودی و ۲۵۶ خروجی دارد و لایه نهایی به تعداد هشت کلاس خروجی تولید می‌کند.

این مدل بدون Augmentation آموزش داده شد و به‌عنوان Baseline برای بررسی اثر سایر روش‌ها مورد استفاده قرار گرفت.

Augmentation 2-2

در این آزمایش معماری مدل ثابت نگه داشته شد و تنها ورودی‌های آموزشی با Augmentation متنوع شدند. نمونه‌های تغییر یافته به صورت on-the-fly تولید شدند و روی دیسک ذخیره نشدند. هدف این روش کاهش وابستگی مدل به زاویه، پس‌زمینه و ویژگی‌های خاص تصاویر آموزشی و در نتیجه افزایش Generalization بود.

Dropout 2-3

Dropout در بخش Classifier و بین دو لایه Fully Connected قرار گرفت و دو مقدار ۰.۳ و ۰.۵ برای آن آزمایش شد. هدف بررسی این بود که حذف تصادفی بخشی از خروجی‌ها تا چه اندازه می‌تواند وابستگی مدل به مسیرهای خاص و بیش‌برازش را کاهش دهد.

Average Pooling 2-4

در این آزمایش Max Pooling با Average Pooling جایگزین شد تا اثر نوع Pooling بر استخراج ویژگی بررسی شود. Max Pooling قوی‌ترین Activation در پنجره را منتقل می‌کند، در حالی که Average Pooling میانگینی از مقادیر را منتقل می‌کند؛ بنابراین این تغییر می‌تواند نوع اطلاعات عبوری در شبکه را تغییر دهد.

Learning Rate Scheduler 2-5

در این آزمایش از StepLR با step_size برابر ۳ و gamma برابر ۰.۱ استفاده شد. ایده اصلی این بود که مدل در ابتدای آموزش با گام‌های بزرگ‌تر حرکت کند و در مراحل پایانی با کاهش نرخ یادگیری، اصلاحات دقیق‌تری انجام دهد.

Weight Decay 2-6

Weight Decay برای محدود کردن اندازه وزن‌ها و کاهش حساسیت مدل به نویز و تغییرات کوچک بررسی شد. هدف اصلی استفاده از این روش کاهش احتمال Overfitting بود.

2-7 عدم توازن داده

برای بررسی اثر عدم توازن کلاس‌ها، Balance Sampler در DataLoader مجموعه آموزش غیرفعال شد. در نتیجه مدل با توزیع واقعی و نامتوازن کلاس‌های آموزشی روبه‌رو شد. سپس عملکرد آن روی مجموعه آزمون بررسی و با حالت‌های دیگر مقایسه شد.

Transfer Learning و ResNet۱۸ 2-8

برای بررسی نقش ظرفیت مدل و ویژگی‌های ازپیش‌آمोخته‌شده، از ResNet۱۸ آموزش‌دیده روی ImageNet استفاده شد و لایه نهایی آن با یک لایه متناسب با هشت کلاس مسئله جایگزین شد. در حالت ResNet Freeze، Backbone کاملاً فریز شد و تنها Head آموزش دید. در حالت Fine-tune، Layer۴ به همراه Head قابل آموزش شد تا ویژگی‌های سطح بالاتر شبکه با مسئله هدف سازگار شوند.

2-9. مقایسه BCE و Cross-Entropy

از آنجا که هر تصویر تنها یک Label دارد، Cross-Entropy انتخاب اصلی برای مسئله است. با این حال برای مقایسه تجربی، مدل پایه با BCE نیز آموزش داده شد. BCE احتمال هر کلاس را به صورت مستقل بررسی می‌کند و معمولاً برای مسائل Multi-Label مناسب‌تر است. نکته مهم این است که مقدار عددی Loss این دو تابع به دلیل تفاوت در نحوه محاسبه مستقیماً قابل مقایسه نیست؛ بنابراین برای ارزیابی عملکرد واقعی از Accuracy، F1 و Confusion Matrix نیز استفاده شد.

3. نتایج و تحلیل آزمایش‌ها

تمام مدل‌های بررسی‌شده روی مجموعه Test شامل ۴۰۰ تصویر ارزیابی شدند. معیارهای گزارش‌شده شامل Accuracy، Macro F1 و Weighted F1 هستند. نتایج زیر مستقیماً از خروجی ارزیابی مدل‌ها استخراج شده‌اند.

مدل / آزمایش	Accuracy	Macro F1	Weighted F1
CNN Base	۰.۷۰	۰.۶۸	۰.۶۷
Augmentation	۰.۶۷	۰.۶۷	۰.۶۶
Dropout ۰.۳	۰.۷۱	۰.۷۱	۰.۷۱
Dropout ۰.۵	۰.۶۵	۰.۶۴	۰.۶۴
Average Pooling	۰.۶۷	۰.۶۷	۰.۶۷
Learning Rate Scheduler	۰.۷۱	۰.۷۱	۰.۷۱
Weight Decay	۰.۷۰	۰.۷۰	۰.۶۹
Imbalanced	۰.۷۱	۰.۷۰	۰.۶۹
ResNet Freeze	۰.۹۰	۰.۸۹	۰.۸۹
ResNet Fine-tune	۰.۹۶	۰.۹۶	۰.۹۶
BCE	۰.۶۸	۰.۶۷	۰.۶۶
Cross-Entropy	۰.۷۰	۰.۶۸	۰.۶۷

3-1. عملکرد مدل پایه

مدل CNN پایه روی مجموعه آزمون به Accuracy برابر ۷۰ درصد و Macro F1 برابر ۰.۶۸ رسید. عملکرد کلاس‌ها یکسان نبود؛ برای مثال F1 کلاس taxi برابر ۰.۹۴ بود، در حالی که F1 کلاس kamyunet تنها ۰.۲۵ به دست آمد. این اختلاف نشان می‌دهد مدل پایه در تفکیک برخی کلاس‌های مشابه با مشکل جدی مواجه بوده است.

3-2. اثر Augmentation

Augmentation در مجموعه آزمون Accuracy را به ۶۷ درصد و Macro F1 را به ۰.۶۷ رساند؛ بنابراین برخلاف انتظار اولیه، بهبود کلی روی Test مشاهده نشد. با این حال در آزمایش‌های آموزشی، کاهش فاصله Train و Validation گزارش شده بود و بنابراین Augmentation از نظر Generalization در روند آموزش اثر مثبتی نشان داد، ولی این اثر در معیار نهایی Test بهبود محسوسی ایجاد نکرد.

3-3. اثر Dropout

Dropout با مقدار ۰.۳ بهترین نتیجه را در میان دو مقدار آزمایش‌شده داشت و Accuracy برابر ۷۱ درصد و Macro F1 برابر ۰.۷۱ به دست آورد. در مقابل، Dropout با مقدار ۰.۵ عملکرد را به Accuracy برابر ۶۵ درصد کاهش داد. این نتیجه نشان می‌دهد Regularization بیش از حد برای این معماری و این مسئله مناسب نبوده و می‌تواند ظرفیت مؤثر مدل برای یادگیری را کاهش دهد.

3-4. Average Pooling

جایگزینی Max Pooling با Average Pooling باعث رسیدن Accuracy به ۶۷ درصد و Macro F1 به ۰.۶۷ شد. بنابراین در این مسئله Max Pooling انتخاب مناسب‌تری برای این معماری بوده است و تغییر Pooling به‌تنهایی نتوانسته محدودیت اصلی مدل را برطرف کند.

3-5. Weight Decay و Scheduler

Learning Rate Scheduler به Accuracy برابر ۷۱ درصد و Macro F1 برابر ۰.۷۱ رسید و در مقایسه با Baseline بهبود محدودی ایجاد کرد. Weight Decay نیز Accuracy برابر ۷۰ درصد و Macro F1 برابر ۰.۷۰ داشت. این نتایج نشان می‌دهند تنظیم روند بهینه‌سازی و Regularization می‌تواند مفید باشد، اما اثر آن‌ها در این معماری محدود است.

3-6. عدم توازن داده

در حالت Imbalanced، Accuracy برابر ۷۱ درصد و Macro F1 برابر ۰.۷۰ به دست آمد. با توجه به Confusion Matrix، برخی کلاس‌ها بیشتر با یکدیگر اشتباه شدند و به‌ویژه کلاس‌هایی با ویژگی‌های بصری مشابه همچنان چالش‌برانگیز بودند. در نتیجه، تنها تغییر توزیع نمونه‌های آموزشی مسئله اصلی را حل نکرد.

3-7. ResNet Freeze

استفاده از ResNet۱۸ در حالت Freeze باعث جهش عملکرد شد. Accuracy به ۹۰ درصد و Macro F1 به ۰.۸۹ رسید. این نتیجه در مقایسه با CNN پایه نشان می‌دهد ویژگی‌های ازپیش‌آموخته‌شده و ظرفیت بالاتر ResNet نقش بسیار مهمی در این مسئله داشته‌اند. همچنین عملکرد کلاس‌ها متعادل‌تر شد و کمترین F1 در این آزمایش حدود ۰.۸۱ بود.

3-8. ResNet Fine-tune

بهترین نتیجه کل پروژه با Fine-tuning به دست آمد. Accuracy روی Test برابر ۹۶ درصد و هر دو معیار Macro F1 و Weighted F1 برابر ۰.۹۶ بودند. F1 کلاس‌ها بین ۰.۹۲ تا ۰.۹۸ قرار گرفت که نشان‌دهنده عملکرد بسیار متوازن‌تر مدل نسبت به CNN پایه است. این نتیجه نشان می‌دهد آموزش مجدد بخشی از لایه‌های انتهایی ResNet باعث شده ویژگی‌های ازپیش‌آموخته‌شده بهتر با ویژگی‌های اختصاصی مسئله طبقه‌بندی خودرو سازگار شوند.

با توجه به اینکه Validation Loss این مدل نیز حدود ۰.۱۴ گزارش شده بود و فاصله عملکرد Train و Validation در آزمایش مربوطه بسیار کم بود، Fine-tuned ResNet به عنوان بهترین مدل انتخاب شد. این مدل در ادامه برای بخش API و Predict پروژه مورد استفاده قرار گرفت.

3-9. مقایسه BCE و Cross-Entropy

مدل Cross-Entropy روی Test به Accuracy برابر ۷۰ درصد و Macro F1 برابر ۰.۶۸ رسید، در حالی که BCE Accuracy برابر ۶۸ درصد و Macro F1 برابر ۰.۶۷ داشت. بنابراین اگرچه در مرحله آموزش مقدار Validation Loss مربوط به BCE پایین تر از Cross-Entropy گزارش شده بود، معیارهای Test نشان می دهند BCE در عملکرد نهایی برتری ایجاد نکرده است. این نتیجه همچنین اهمیت مقایسه معیارهای عملکرد واقعی را در کنار مقدار Loss نشان می دهد.

4. تحلیل کلی نتایج

نتایج آزمایش ها یک الگوی مشخص را نشان می دهند. در مدل CNN پایه، تغییرات مربوط به داده، Pooling، Regularization و Scheduler عموماً عملکرد را در محدوده ۶۵ تا ۷۱ درصد نگه داشتند. بنابراین این آزمایش ها اگرچه برای شناخت رفتار مدل مفید بودند، اما نشان دادند که محدودیت اصلی احتمالاً تنها Overfitting یا روش بهینه سازی نیست و ظرفیت معماری نیز نقش مهمی دارد.

در مقابل، انتقال به ResNet۱۸ باعث افزایش شدید عملکرد شد؛ حتی در حالت Freeze، Accuracy از ۷۰ درصد به ۹۰ درصد رسید. Fine-tuning این مقدار را به ۹۶ درصد افزایش داد. این جهش نسبت به تغییرات کوچک CNN پایه بسیار بزرگ تر است و نشان می دهد استفاده از یک معماری عمیق تر همراه با ویژگی های از پیش آموخته شده، راهکار مؤثرتری برای این مسئله بوده است.

از طرف دیگر، Confusion Matrix مدل پایه نشان می داد برخی کلاس ها، به خصوص kamyunet، به شدت با سایر کلاس ها اشتباه می شوند. در مدل Fine-tuned، عملکرد این کلاس نیز به F1 برابر ۰.۹۴ رسید. بنابراین مدل نهایی نه تنها Accuracy کلی را افزایش داده، بلکه مشکل عدم تعادل عملکرد بین کلاس ها را نیز تا حد زیادی کاهش داده است.

5. محدودیت ها و مسیرهای ادامه کار

مهم ترین محدودیت پروژه ظرفیت مدل CNN پایه و دشواری تفکیک برخی کلاس های بصری مشابه بود. آزمایش ها نشان دادند که افزودن تکنیک های ساده به این معماری به تنهایی کافی نیست. همچنین ارزیابی ها روی یک مجموعه Test با ۴۰۰ تصویر انجام شده است؛ بنابراین برای اطمینان بیشتر از پایداری نتایج می توان در ادامه از ارزیابی های تکرارشونده یا Cross-Validation استفاده کرد.

در ادامه می توان Fine-tuning را با تنظیم دقیق تر Learning Rate برای Backbone و Head، آزمایش معماری های قوی تر، بررسی Augmentation در کنار ResNet، و تحلیل دقیق تر خطاهای هر کلاس ادامه داد. همچنین بررسی کیفیت و تنوع داده ها و نمونه هایی که مدل در آن ها اشتباه می کند می تواند برای بهبود بیشتر مفید باشد.

6. نتیجه گیری

در این پروژه یک مسئله طبقه بندی هشت کلاسه تصاویر خودرو با مجموعه ای از آزمایش های مرحله ای بررسی شد. ابتدا یک CNN پایه به عنوان Baseline ساخته شد و سپس اثر Augmentation، Dropout، Average Pooling، Learning Rate Scheduler، Weight Decay

و عدم توازن داده بررسی شد. این آزمایش‌ها نشان دادند که تغییرات موضعی در معماری و روند آموزش، در بهترین حالت بهبود محدودی ایجاد می‌کنند.

در مرحله بعد، استفاده از ResNet۱۸ و Transfer Learning تغییر اصلی را ایجاد کرد. ResNet در حالت Freeze به Accuracy برابر ۹۰ درصد رسید و با Fine-tuning، بهترین عملکرد پروژه یعنی Accuracy و Macro F۱ برابر ۹۶ درصد روی مجموعه Test به دست آمد. در نتیجه، خروجی نهایی پروژه نشان می‌دهد که برای این مسئله، افزایش ظرفیت مدل و سازگار کردن ویژگی‌های ازپیش‌آموخته‌شده با داده هدف بسیار مؤثرتر از اعمال تغییرات کوچک روی CNN پایه بوده است.

در نهایت، مدل ResNet Fine-tuned به‌عنوان مدل نهایی انتخاب شد و برای بخش API و Predict پروژه مورد استفاده قرار گرفت. با وجود عملکرد بالای مدل، بررسی نمونه‌های خطا دار و ارزیابی روی داده‌های متنوع‌تر همچنان می‌تواند زمینه بهبود و ادامه توسعه پروژه باشد.

7. جمع‌بندی نتایج نهایی

نتیجه	شاخص
ResNet۱۸ Fine-tuned	بهترین مدل
۹۶٪	Test Accuracy
۰.۹۶	Macro F۱
۰.۹۶	Weighted F۱
۴۰۰	تعداد نمونه‌های Test
Scheduler / ۰.۳ Dropout با Accuracy برابر ۷۱٪	بهترین CNN پایه
ResNet Fine-tune	مدل انتخاب‌شده برای API